

# Thuật toán

$$\min_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i)) + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2$$

Giả sử với mọi  $i \in \{1, \dots, n\}$ ,  $k(x_i, x_i) = \|\varphi(x_i)\|^2 \leq R^2$

-Định lý đại diện:

$$\min_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n \ell(y_i, (K\alpha)_i) + \frac{\lambda}{2} \alpha^\top K \alpha.$$

=> Tối ưu hóa lồi

-Xét trường hợp đặc biệt của hàm mất mát bình phương (Ridge Regression):

$$\min_{\alpha \in \mathbb{R}^n} \frac{1}{2n} \|y - K\alpha\|_2^2 + \frac{\lambda}{2} \alpha^\top K \alpha.$$

$$\min_{\alpha \in \mathbb{R}^n} \frac{1}{2n} \|y - K\alpha\|_2^2 + \frac{\lambda}{2} \alpha^\top K \alpha.$$

-Tính đạo hàm:  $\frac{1}{2n} \cdot (-2K^\top) \cdot (y - K\alpha) + \frac{\lambda}{2} \cdot (K + K^\top) \cdot \alpha$

$$\Leftrightarrow (K^2 + n\lambda K)\alpha = Ky$$

$$\Leftrightarrow \alpha = (K + n\lambda I)^{-1}y$$

- K thường có trị riêng rất nhỏ => **tối ưu không tốt**

$$+ \text{ Hessians} = \frac{1}{n} K \text{Diag}(h) K + \lambda K \quad h \in \mathbb{R}^n$$

- Tính căn bậc 2 của K =  $\Phi\Phi^T$

$$+ \text{ Xét } \min_{\beta \in \mathbb{R}^m} \frac{1}{n} \sum_{i=1}^n \ell(y_i, (\Phi\beta)_i) + \frac{\lambda}{2} \|\beta\|_2^2 \quad \left\{ \begin{array}{l} \Phi \in \mathbb{R}^{n \times m} \\ m \text{ là hạng của ma trận } K \\ \alpha = \Phi^T \beta \end{array} \right.$$

- Trong trường hợp Ridge Regression, trị riêng nhỏ nhất  $> \lambda$  => **tối ưu tốt**

$$+ \text{ Hessian(hàm mục tiêu)} = \frac{1}{n} \Phi^T \Phi + \lambda I$$

# Xấp xỉ Nyström

-Việc thực hiện tính trên có thể theo 1 số cách như phân rã Cholesky hoặc SVD

+ Xét  $K \in \mathbb{R}^{n \times n} \rightarrow K \approx K(V, I)K(I, I)^{-1}K(I, V)$

**Column sampling:** Với  $K(A, B)$  là ma trận con của  $K$ , có được bằng cách lấy các hàng từ  $A \subset \{1, \dots, n\}$ , các cột từ  $B \subset \{1, \dots, n\}$  và  $V = \subset \{1, \dots, n\}$ .

+ Xét với  $I = \{1, \dots, m\}$  :

$\Rightarrow \Phi = K(V, I)K(I, I)^{-1/2}$

$\left\{ \begin{array}{l} \Phi \in \mathbb{R}^{n \times m} \\ m = ||I|| \end{array} \right.$

$K(I, I)$	$K(I, J)$
$K(J, I)$	$K(J, J)$

**Random feature:** Một số kernel có dạng đặc biệt dẫn đến xấp xỉ cụ thể sau:

$$k(x, x') = \int_{\mathcal{V}} \varphi(x, v) \varphi(x', v) d\mu(v) \quad \left\{ \begin{array}{l} d\mu : \text{phân phối xác suất trên KG } \mathcal{V} \\ \varphi(x, v) \in \mathbb{R} \end{array} \right.$$

- Có thể xấp xỉ kỳ vọng như sau:

$$\hat{k}(x, x') = \frac{1}{m} \sum_{i=1}^m \varphi(x, v_i) \varphi(x', v_i) \longrightarrow \min_{\beta \in \mathbb{R}^m} \frac{1}{n} \sum_{i=1}^n \ell(y_i, \hat{\varphi}(x_i)^\top \beta) + \frac{\lambda}{2} \|\beta\|_2^2.$$

$$\left\{ \begin{array}{l} \text{- Với } \varphi(x) = \frac{1}{\sqrt{m}} \varphi(x, v_i), i \in \{1, \dots, m\} \end{array} \right.$$

- m phải nhỏ hơn n đáng kể, thường là vừa đủ thực tế

-Việc làm giảm kích thước như trên có thể thực hiện độc lập với dữ liệu đầu vào (Random feature hàm  $\varphi(\cdot, v_i)$ ), trái với Column sampling thực hiện phụ thuộc.

ví dụ:

**+ kernels tịnh tiến bất biến:**  $k(x, y) = q(x - y) = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \hat{q}(\omega) e^{i\omega^\top (x-y)} d\omega$

$\omega$  : được lấy mẫu từ phân phối với mật độ  $\frac{1}{(2\pi)^d} \frac{q(\omega)}{q(0)}$  (phân phối Gauss cho Gaussian Kernel)

$$\varphi(x, \omega) = \sqrt{q(0)} e^{i\omega^\top x} \in \mathbb{C},$$

-> Thay thế feature  $\in \mathbb{C}$  bởi feature  $\in \mathbb{R}$ :  $\sqrt{2} \cos(\omega^\top x + b)$   
( $b \in [0, 2\pi]$ )

**+ Mạng nơ-ron với trọng số ngẫu nhiên:**  $\varphi(x, v) = \sigma(v^\top x)$  với  $\sigma: \mathbb{R} \rightarrow \mathbb{R}$

$$k(x, x') = \frac{\|x\|_2 \|x'\|_2}{2(d+1)\pi} [(\pi - \eta) \cos \eta + \sin \eta] \text{ với } \cos \eta = \frac{x^\top x'}{\|x\|_2 \|x'\|_2}$$

=> một mạng nơ-ron với 1 lượng lớn nơ-ron ẩn, với trọng số đầu vào ngẫu nhiên không tối ưu như kernel method.

# Thuật toán đối ngẫu

$$f(x) = \langle \varphi(x), \theta \rangle \text{ với } \theta \in H$$

$$\text{Dùng đối ngẫu Lagrange giải : } \min_{\theta \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \ell(y_i, \langle \varphi(x_i), \theta \rangle) + \frac{\lambda}{2} \|\theta\|^2$$

$$= \min_{\theta \in \mathcal{H}, u \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n \ell(y_i, u_i) + \frac{\lambda}{2} \|\theta\|^2 \quad \forall i \in \{1, \dots, n\}, \langle \varphi(x_i), \theta \rangle = u_i$$

$$\begin{aligned} \text{Xét: } & \max_{\alpha \in \mathbb{R}^n} \min_{\theta \in \mathcal{H}, u \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n \ell(y_i, u_i) + \frac{\lambda}{2} \|\theta\|^2 + \lambda \sum_{i=1}^n \alpha_i (u_i - \langle \varphi(x_i), \theta \rangle) \\ &= \max_{\alpha \in \mathbb{R}^n} \left\{ \frac{1}{n} \sum_{i=1}^n \min_{u_i \in \mathbb{R}} \{ \ell(y_i, u_i) + n\lambda\alpha_i u_i \} + \min_{\theta \in \mathcal{H}} \left\{ \frac{\lambda}{2} \|\theta\|^2 - \lambda \sum_{i=1}^n \alpha_i \langle \varphi(x_i), \theta \rangle \right\} \right\} \\ &= \max_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n \min_{u_i \in \mathbb{R}} \{ \ell(y_i, u_i) + n\lambda\alpha_i u_i \} - \frac{\lambda}{2} \left\| \sum_{i=1}^n \alpha_i \varphi(x_i) \right\|^2 \quad \text{với } \theta = \sum_{i=1}^n \alpha_i \varphi(x_i), \\ &= \max_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n \min_{u_i \in \mathbb{R}} \{ \ell(y_i, u_i) + n\lambda\alpha_i u_i \} - \frac{\lambda}{2} \alpha^\top K \alpha \end{aligned}$$



$$\max_{\alpha \in \mathbb{R}^n} \frac{1}{n} \sum_{i=1}^n \min_{u_i \in \mathbb{R}} \{ \ell(y_i, u_i) + n\lambda \alpha_i u_i \} - \frac{1}{2\lambda} \alpha^\top K \alpha$$

với  $\theta = \sum_{i=1}^n \alpha_i \varphi(x_i)$ , tối ưu

Vì hàm  $\alpha_i \mapsto \min_{u_i \in \mathbb{R}} \{ \ell(y_i, u_i) + n\lambda \alpha_i u_i \}$  lõm, bài toán trên thành tìm cực đại lõm

# SGD (Stochastic Gradient Descent)

$$\min_{\theta \in \mathcal{H}} \mathbb{E} [\ell(y, \langle \varphi(x), \theta \rangle)] + \frac{\lambda}{2} \|\theta\|^2$$

-Khi tối ưu, SGD dẫn đến đệ quy:

$$\theta_t = \theta_{t-1} - \gamma_t [\ell'(y_t, \langle \varphi(x_t), \theta_{t-1} \rangle) \varphi(x_t) + \lambda \theta_{t-1}]$$

-Khi khởi tạo  $\theta_0 = 0$ ,  $\theta_t$  là tổ hợp tuyến tính của  $\varphi(x_i)$ ,  $i = 1, \dots, t$

$$\theta_t = \sum_{i=1}^t \alpha_i^{(t)} \varphi(x_i),$$

-Với  $\alpha^{(0)} = 0$ , đệ quy trên trở thành:

$$\alpha_i^{(t)} = (1 - \gamma_t \lambda) \alpha_i^{(t-1)} \text{ for } i \in \{1, \dots, t-1\} \text{ với } \alpha_t^{(t)} = -\gamma_t \ell' \left( y_t, \sum_{i=1}^{t-1} \alpha_i^{(t-1)} k(x_t, x_i) \right)$$

+Nếu hàm mất mát G-Lipschitz liên tục với:  $F(\theta) = \mathbb{E}[\ell(y, \langle \varphi(x), \theta \rangle)] + \frac{\lambda}{2} \|\theta\|^2$

$$\mathbb{E}[F(\bar{\theta}_t)] - \inf_{\theta \in \mathcal{H}} F(\theta) \leq \frac{G^2 R^2}{\lambda t}$$

$$\mathbb{E}[\mathcal{R}(f_{\bar{\theta}_t})] \leq \frac{G^2 R^2}{\lambda n} + \inf_{f \in \mathcal{H}} \left\{ \mathcal{R}(f) + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2 \right\}$$

=>**Tổng kết 7.4** - “Kernelization” của các thuật toán tuyến tính:


+ học có giám sát, nhiều thuật toán học không giám sát có thể được “kernelized” như PCA(Principle component analysis) và CCA(canonical correlation analysis)

# Bảo toàn tổng quát– Mất mát Lipschitz liên tục

+ Xét hàm mất mát G-Lipschitz, xét cực tiểu  $\hat{f}_D^{(c)}$  :

$$\min_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i)) \text{ such that } \|f\|_{\mathcal{H}} \leq D$$

$$\min_{f \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \ell(y_i, f(x_i)) + \frac{\lambda}{2} \|f\|_{\mathcal{H}}^2$$



+ Đặt  $\mathcal{R}(f) = \mathbb{E}[\ell(y, f(x))]$  : Rủi ro kỳ vọng, và  $f^*$  -- Một trong những cực tiểu  
 -- Giả sử  $K(x, x) \leq R^2$

$$\begin{aligned} \mathcal{R}(f) - \mathcal{R}(f^*) &\leq \mathbb{E}[|\ell(y, f(x)) - \ell(y, f^*(x))|] \leq G \mathbb{E}[|f(x) - f^*(x)|] \\ &\leq G \sqrt{\mathbb{E}[|f(x) - f^*(x)|^2]} = G \|f - f^*\|_{L_2(dp(x))} \end{aligned}$$

$$\|f\|_{L_2(dp(x))} \leq \left\| \frac{dp}{dx} \right\|_{\infty}^{1/2} \|f\|_{L_2(dx)} \Rightarrow \text{thay } G \|f - f^*\|_{L_2(dp(x))} \text{ bởi } G \left\| \frac{dp}{dx} \right\|_{\infty}^{1/2} \|f - f^*\|_{L_2(dx)}.$$

## a) Phân rã rủi ro

+ Vấn đề hạn chế: Dựa trên phân phối Rademacher, sai số ước tính có giới hạn trên là  $\frac{2GDR}{\sqrt{n}}$

$$\mathbb{E}[\mathcal{R}(\hat{f}_D^{(c)})] - \mathcal{R}(f^*) \leq \underbrace{\frac{2GDR}{\sqrt{n}}}_{\text{Sai số ước tính}} + \underbrace{G \inf_{\|f\|_{\mathcal{H}} \leq D} \|f - f^*\|_{L_2(dp(x))}}_{\text{Sai số xấp xỉ}}$$

+ Tìm cách cực tiểu hóa theo D bằng đối ngẫu Lagrange:

$$\inf_{D \geq 0} \frac{2GRD}{\sqrt{n}} + G \inf_{\|f\|_{\mathcal{H}} \leq D} \|f - f^*\|_{L_2(dp)}$$

$$\inf_{D \geq 0} \frac{2GRD}{\sqrt{n}} + G \inf_{\|f\|_{\mathcal{H}} \leq D} \|f - f^*\|_{L_2(dp)}$$

$$= \inf_{D \geq 0} \frac{2GBD}{\sqrt{n}} + G \sup_{\lambda \geq 0} \inf_{f \in \mathcal{H}} \|f - f^*\|_{L_2(dp(x))} + \sqrt{\lambda}(\|f\|_{\mathcal{H}} - D)$$

$$\leq \sup_{\lambda \geq 0} \inf_{D \geq 0} GD \left[ \frac{2R}{\sqrt{n}} - \sqrt{\lambda} \right] + 2G \sqrt{\inf_{f \in \mathcal{H}} \{ \|f - f^*\|_{L_2(dp(x))}^2 + \lambda \|f\|_{\mathcal{H}}^2 \}} \quad \text{Áp dụng } a + b \leq 2\sqrt{a^2 + b^2}$$

$$= \sup_{\lambda \geq 0} G \sqrt{\inf_{f \in \mathcal{H}} \{ \|f - f^*\|_{L_2(dp(x))}^2 + \lambda \|f\|_{\mathcal{H}}^2 \}} \quad \text{với } \sqrt{\lambda} \leq \frac{2R}{\sqrt{n}}$$

$$\leq 2G \sqrt{\inf_{f \in \mathcal{H}} \{ \|f - f^*\|_{L_2(dp(x))}^2 + \frac{4R^2}{n} \|f\|_{\mathcal{H}}^2 \}} \quad \text{với } \lambda^* = \frac{4R^2}{n}$$

$$A(\lambda, f^*) = \inf_{f \in \mathcal{H}} \{ \|f - f^*\|_{L_2(dp(x))}^2 + \lambda \|f\|_{\mathcal{H}}^2 \}$$

-  $A \rightarrow 0$  khi  $\lambda \rightarrow 0$  trong 1 số trường hợp sau:

- Nếu  $f^*$  trong  $H$ ,  $A(\lambda, f^*) = \lambda \|f^*\|_{\mathcal{H}}^2$

- Nếu  $f^*$  không trong  $H$ , nhưng có thể tiệm cận khi  $f^*$  là bao hàm  $L_2(dp(x))$

- Biểu thị  $\Pi_{\bar{H}}(f^*)$  là phép chiếu trực giao trong  $L_2(dp(x))$  của  $f^*$  trên bao hàm  $H$  bằng định lý Py-ta-go  $A(\lambda, f^*) = A(\lambda, \Pi_{\bar{H}}(f^*)) + \|f^* - \Pi_{\bar{H}}(f^*)\|_{L_2(dp(x))}^2$

Tuy nhiên xảy ra ko thể nén được do lựa chọn không gian hàm không đủ lớn.

## Vấn đề hiệu chuẩn:

$$\mathbb{E}[\mathcal{R}(\hat{f}_\lambda^{(r)})] - \mathcal{R}(f^*) \leq \frac{32G^2 R^2}{\lambda n} + \inf_{f \in \mathcal{H}} \left\{ G\|f - f^*\|_{L_2(dp(x))} + \frac{\lambda}{2}\|f\|_{\mathcal{H}}^2 \right\}.$$

- Cực tiểu hóa giới hạn với  $\lambda$ ,  $\lambda^* = \frac{8RG}{\sqrt{n}}$

$$G \inf_{f \in \mathcal{H}} \left\{ \|f - f^*\|_{L_2(dp(x))} + \frac{8R}{\sqrt{n}}\|f\|_{\mathcal{H}} \right\} \leq 2G \sqrt{\inf_{f \in \mathcal{H}} \left\{ \|f - f^*\|_{L_2(dp)}^2 + \frac{64R^2}{n}\|f\|_{\mathcal{H}}^2 \right\}}$$

- biểu thức bị **hạn chế** ở 1 số ràng buộc nhưng là 1 cách tối ưu đc sử dụng phổ biến trong thực tế. Tham số Regularization tỉ lệ với  $R^2/n$ .



## b) Sai số xấp xỉ cho “kernels bất biến liên tục” trên $\mathbb{R}^d$

-Với 1 phân phối  $dp(x)$ , mục tiêu là tính:

$$A(\lambda, f^*) = \inf_{f \in \mathcal{H}} \|f - f^*\|_{L_2(dp(x))}^2 + \lambda \|f\|_{\mathcal{H}}^2$$

-Giả sử  $\|f - f^*\|_{L_2(dp(x))}^2 \leq C \|f - f^*\|_{L_2(dx)}^2$   $\left\{ \begin{array}{l} C = \|dp/dx\|_{\infty} \\ dp/dx \text{ là mật độ của } dp(x) \\ \|f^*\|_{L_2(dx)} \text{ hữu hạn} \end{array} \right.$

-Đưa ra giới hạn trên  $\tilde{A}(\lambda, f^*) = \inf_{f \in \mathcal{H}} \|f - f^*\|_{L_2(dx)}^2 + \lambda \|f\|_{\mathcal{H}}^2$

-Nếu  $f^* \in \mathcal{H}$  (best case)  $\Rightarrow \tilde{A}(\lambda, f^*) = \lambda \|f^*\|_{\mathcal{H}}^2$

## Xấp xỉ tường minh:

- Đối với kernels bất biến liên tục,  $\|f\|_{\mathcal{H}}^2 = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \frac{|\hat{f}(\omega)|^2}{\hat{q}(\omega)} d\omega$

$$\Rightarrow \tilde{A}(\lambda, f^*) = \inf_{\hat{f} \in L_2(d\omega)} \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \left[ |\hat{f}(\omega) - \hat{f}^*(\omega)|^2 + \lambda \frac{|\hat{f}(\omega)|^2}{\hat{q}(\omega)} \right] d\omega$$

- Việc tối ưu được thực hiện độc lập với  $\omega$ , trên là hàm bậc 2

$\Rightarrow$  Tính đạo hàm theo  $\hat{f}(\omega)$

$$0 = 2(\hat{f}(\omega) - \hat{f}^*(\omega)) + 2\lambda \frac{\hat{f}(\omega)}{\hat{q}(\omega)}$$

$$\Leftrightarrow \hat{f}_\lambda(\omega) = \frac{\hat{f}^*(\omega)}{1 + \lambda \hat{q}(\omega)^{-1}}$$

- Đối với hàm mục tiêu, ta có:

$$\tilde{A}(\lambda, f^*) = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \left[ |\hat{f}^*(\omega)|^2 \left( 1 - \frac{1}{1 + \lambda \hat{q}(\omega)^{-1}} \right) \right] d\omega = \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} \left[ |\hat{f}^*(\omega)|^2 \frac{\lambda}{\hat{q}(\omega) + \lambda} \right] d\omega.$$

- Khi  $\lambda \rightarrow 0$ , với mỗi  $\omega$ ,  $\hat{f}_\lambda(\omega) \rightarrow \hat{f}(\omega)$

- Theo định lý hội tụ,  $\tilde{A}(\lambda, f^*) \rightarrow 0$  khi  $\lambda \rightarrow 0$

# Không gian Sobolev

- Giả sử:  $\frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} (1 + \|\omega\|_2^2)^t |\hat{f}^*(\omega)|^2 d\omega$  hữu hạn khi  $t > 0$

- Đối với  $f^*$  có đạo hàm riêng của tích phân bình phương lên đến bậc  $t$ , ta có thể xét:

$$\tilde{A}(\lambda, f^*) \leq \frac{1}{(2\pi)^d} \int_{\mathbb{R}^d} (1 + \|\omega\|_2^2)^t |\hat{f}^*(\omega)|^2 d\omega \times \sup_{\omega \in \mathbb{R}^d} \left\{ \frac{\lambda}{\hat{q}(\omega) + \lambda} \frac{1}{(1 + \|\omega\|_2^2)^t} \right\}$$

- Nếu giả sử  $\hat{q}(\omega) \propto (1 + \|\omega\|_2^2)^{-s}$  (Matern Kernels) với  $s > d/2$  để có RKHS,

-  $t \geq s$ ,  $f^* \in H \Rightarrow \tilde{A}(\lambda, f^*) = \lambda \|f^*\|_{\mathcal{H}}^2$

-  $t < s$ ,  $f^*$  không  $\in H \Rightarrow \sup_{\omega \in \mathbb{R}^d} \left\{ \frac{\lambda}{\hat{q}(\omega) + \lambda} \frac{1}{(1 + \|\omega\|_2^2)^t} \right\} \leq \sup_{\omega \in \mathbb{R}^d} \left\{ \frac{\lambda}{\hat{q}(\omega)^{t/s} \lambda^{1-t/s}} \frac{1}{(1 + \|\omega\|_2^2)^t} \right\} = O(\lambda^{t/s}).$

+Áp dụng  $a + b \geq a^{t/s} b^{1-t/s}$

# Giới hạn xấp xỉ

- Xấp xỉ  $f^*$   $\rightarrow \varepsilon$  với RKHS norm nhỏ nhất có thể:

$$A(\lambda, f^*) = \inf_{f \in \mathcal{H}} \{ \|f - f^*\|_{L_2(dp(x))}^2 + \lambda \|f\|_{\mathcal{H}}^2 \}$$

Có dạng  $c\lambda^\alpha$  với  $\alpha \in (0,1)$  :

$$\begin{aligned} & \inf_{f \in \mathcal{H}} \|f\|_{\mathcal{H}}^2 \text{ such that } \|f - f^*\|_{L_2(dp(x))} \leq \varepsilon \\ &= \inf_{f \in \mathcal{H}} \sup_{\mu \geq 0} \|f\|_{\mathcal{H}}^2 + \mu(\|f - f^*\|_{L_2(dp(x))}^2 - \varepsilon^2) \quad \text{Dùng đối ngẫu Lagrange} \\ &= \sup_{\mu \geq 0} \mu A(\mu^{-1}, f^*) - \mu \varepsilon^2 \leq \sup_{\mu \geq 0} \mu c \mu^{-\alpha} - \mu \varepsilon^2 \end{aligned}$$

$$\sup_{\mu \geq 0} \mu A(\mu^{-1}, f^*) - \mu \varepsilon^2 \leq \sup_{\mu \geq 0} \mu c \mu^{-\alpha} - \mu \varepsilon^2$$

-  $\mu$  tối ưu thỏa mãn  $(1 - \alpha)c\mu^{-\alpha} = \varepsilon^2$

$$\rightarrow \varepsilon^{2(1 - 1/\alpha)} = \varepsilon^{-2(1 - \alpha)/\alpha}$$

- Với  $\alpha = t/s \Rightarrow$  RKHS norm tỉ lệ với  $\varepsilon^{-(1 - \alpha)/\alpha}$  để có được sai số nhỏ hơn  $\|f - f^*\|_{L_2(dx)}$

- Xét  $t = 1$  và  $s > d/2$  (Sobolev kernel), có norm bậc:

$$\varepsilon^{-(1/\alpha - 1)} = \varepsilon^{-(s - 1)} \geq \varepsilon^{-d/2 + 1}$$

-> kích thước tăng nhanh theo cấp số mũ

$\rightarrow$  Đây là 1 cách để phát sinh số chiều khác